TECLA: Guía de Uso

Herramienta de Extracción de Términos y Lingüística de Corpus

Versión 2.0.0 | Julio 2026

Tabla de Contenidos

1. Introducción
2. Instalación
3. Inicio Rápido
4. Línea de Comandos
5. API Python
6. Aplicación GUI
7. Ejemplos
8. Solución de Problemas
9. Citación

Introducción

TECLA es una herramienta completa para extracción automática de terminología de corpus especializados. Combina:

- **Filtrado Lingüístico**: Coincidencia de patrones basada en POS (etiquetas gramaticales)
- **Puntuación Estadística**: Medidas TF-IDF y C-value
- **Soporte Bilingüe**: Inglés y Español
- **Múltiples Interfaces**: CLI, API Python, y GUI

Casos de Uso

- Construir glosarios a partir de textos académicos
- Extraer terminología médica
- Extraer terminología jurídica
- Extraer términos científicos
- Crear bancos de términos bilingües

Instalación

Requisitos Previos

- Python 3.9 o superior
- pip (gestor de paquetes Python)

Paso 1: Descargar Modelos de spaCy

```
python -m spacy download es_core_news_md  # Para español
python -m spacy download en_core_web_md   # Para inglés
```

Paso 2: Instalar TECLA

```
# Navega al directorio de TECLA
cd /ruta/a/tecla

# Instala en modo desarrollo
pip install -e .
```

Paso 3: Verificar Instalación

```
python -m tecla --help
```

Deberías ver el menú de ayuda principal.

Inicio Rápido

Ejemplo en 5 Minutos

Crea un corpus de prueba con dos archivos de texto:

doc1.txt:

```
La lingüística de corpus es el estudio del lenguaje a través de
grandes colecciones de textos. El procesamiento del lenguaje natural
utiliza métodos computacionales para analizar corpus.
```

doc2.txt:

```
Los corpus lingüísticos son recursos fundamentales para la
investigación terminológica. La extracción automática de términos
facilita la creación de glosarios.
```

Extrae los términos:

```
python -m tecla extract \
  --corpus ./mis_textos/ \
  --lang es \
  --top-k 10 \
  --output resultados.csv
```

Visualiza los resultados:

```
cat resultados.csv
```

Salida:

```
term,frequency,doc_frequency,terminologicity
corpus,3,2,0.9139
lenguaje,2,1,0.8999
terminología,2,2,0.4095
```

Línea de Comandos

Comandos Principales

TECLA proporciona tres comandos principales:

```
tecla extract   - Extraer términos de un corpus
tecla stats     - Calcular estadísticas del corpus
tecla evaluate  - Evaluar contra estándar de oro
```

1. Extraer Términos

Extrae terminología de un corpus.

```
python -m tecla extract \
  --corpus RUTA/AL/CORPUS \
  --lang IDIOMA \
  --top-k NÚMERO \
  --output SALIDA.csv
```

Parámetros:

Parámetro	Requerido	Valores	Descripción
`--corpus`	Sí	Ruta	Directorio con archivos TXT
`--lang`	Sí	es, en	Idioma del corpus
`--output`	No	Ruta	Archivo CSV de salida (por defecto: terms.csv)
`--top-k`	No	Entero	Número de términos a extraer (por defecto: 100)
`--tfidf-weight`	No	0-1	Peso de TF-IDF en puntuación (por defecto: 0.6)

Ejemplo (Español):

```
python -m tecla extract \
  --corpus ./corpus_es/ \
  --lang es \
  --top-k 50 \
  --output terminos_es.csv
```

Columnas de Salida:

- `term`: Término extraído
- `lemma`: Forma lematizada
- `frequency`: Total de ocurrencias
- `doc_frequency`: Número de documentos con el término
- `tf_idf`: Puntuación TF-IDF
- `c_value`: Puntuación C-value (especificidad)
- `terminologicity`: Puntuación compuesta (0-1)

---

2. Calcular Estadísticas

Analiza características del corpus.

```
python -m tecla stats --corpus RUTA/AL/CORPUS --lang IDIOMA
```

Ejemplo:

```
python -m tecla stats --corpus ./corpus_es/ --lang es
```

Salida Ejemplo:

```
Estadísticas del corpus - 15 documento(s)

Archivo                Tokens    Tipos    TTR    Oraciones

  doc1.txt             1.245      892     0.716     42
  doc2.txt               856      723     0.845     28
  ...

Total                 12.456    3.412     0.274    340
```

Métricas Explicadas:

- **Tokens**: Conteo total de palabras
- **Tipos**: Tamaño del vocabulario único
- **TTR** (Ratio Tipo-Token): Riqueza de vocabulario (0-1, mayor = más rico)
- **Heaps** : Tasa de crecimiento del vocabulario

---

3. Evaluar Extracción

Compara los términos extraídos con un glosario de referencia.

```
python -m tecla evaluate \
  --predicted TERMINOS.csv \
  --gold-standard REFERENCIA.txt \
  --lang IDIOMA
```

Formato de Referencia (REFERENCIA.txt):

```
lingüística de corpus
procesamiento del lenguaje natural
extracción de términos
métodos estadísticos
```

Salida:

```
Resultados de Evaluación

Precisión:  0.847
Recall:     0.723
```

```
F1-score:   0.781
```

API Python

Utiliza TECLA directamente en scripts Python.

Ejemplo Básico

```python
from tecla import HybridTermExtractor

# Inicializa el extractor
extractor = HybridTermExtractor(language="es")

# Prepara documentos
documentos = [
    {
        "text": "La lingüística de corpus estudia el lenguaje...",
        "doc_id": "doc1",
        "language": "es"
    },
    {
        "text": "El procesamiento del lenguaje natural...",
        "doc_id": "doc2",
        "language": "es"
    }
]

# Extrae términos
terminos = extractor.extract(documentos, top_k=20)

# Imprime resultados
for i, termino in enumerate(terminos[:5], 1):
    print(f"{i}. {termino['text']:<30} {termino['score']:.3f}")
```

Cargar Corpus desde Archivos

```python
from tecla import build_corpus_from_txt

# Construye el corpus
corpus = build_corpus_from_txt(
    input_dir="ruta/a/textos/",
    language="es",
    clean=True,
    spacy_model="es_core_news_md"
)
```

```python
# Extrae del corpus
terminos = extractor.extract(corpus, top_k=50)
```

Calcular Estadísticas

```python
from tecla import corpus_statistics

estadisticas = corpus_statistics(
    corpus_dir="ruta/a/corpus/",
    language="es"
)

print(f"Tokens totales: {estadisticas['total_tokens']}")
print(f"Tipos únicos: {estadisticas['unique_types']}")
print(f"Ratio Tipo-Token: {estadisticas['type_token_ratio']:.3f}")
print(f"Heaps  : {estadisticas['heaps_beta']:.3f}")
```

Flujo de Trabajo Completo

```python
from tecla import (
    HybridTermExtractor,
    build_corpus_from_txt,
    corpus_statistics,
    evaluate_extraction
)

# 1. Construir corpus
print("Construyendo corpus...")
corpus = build_corpus_from_txt(
    input_dir="corpus/",
    language="es",
    clean=True,
    spacy_model="es_core_news_md"
)

# 2. Extraer términos
print("Extrayendo términos...")
extractor = HybridTermExtractor(language="es")
terminos = extractor.extract(corpus, top_k=100)

# 3. Obtener estadísticas
print("Calculando estadísticas...")
estadisticas = corpus_statistics("corpus/", "es")
print(f"Tamaño del corpus: {estadisticas['total_tokens']} tokens")

# 4. Evaluar
print("Evaluando contra referencia...")
metricas = evaluate_extraction(
```

```
    predicted_terms=terminos,
    gold_standard_file="glosario_referencia.txt",
    language="es"
)

print(f"Precisión: {metricas['precision']:.3f}")
print(f"Recall: {metricas['recall']:.3f}")
print(f"F1-score: {metricas['f1']:.3f}")
```

Aplicación GUI

TECLA incluye una interfaz gráfica para usuarios no técnicos.

Lanzar la GUI

```
python gui/tecla_gui.py
```

Descripción de la Interfaz

La GUI proporciona:

1. **Selección de Corpus**: Explorar y seleccionar carpeta del corpus
2. **Elección de Idioma**: Seleccionar idioma (ES/EN)
3. **Configuración de Parámetros**: Ajustar parámetros de extracción
4. **Monitoreo de Progreso**: Progreso en tiempo real
5. **Visor de Resultados**: Visualizar y exportar resultados
6. **Panel de Estadísticas**: Ver métricas del corpus

Guía Paso a Paso

1. **Haz clic en "Examinar"** para seleccionar la carpeta del corpus
2. **Elige Idioma** del menú desplegable
3. **Establece Top-K** (número de términos a extraer)
4. **Haz clic en "Extraer"** para iniciar el proceso
5. **Ve los Resultados** en la tabla de resultados
6. **Exporta CSV** usando el botón "Guardar Resultados"

Ejemplos

Ejemplo 1: Análisis de Artículos Académicos

Extrae terminología de artículos académicos:

```
# Estructura de directorios
articulos/
  articulo1.txt
  articulo2.txt
  articulo3.txt
```

```bash
# Extrae
python -m tecla extract \
  --corpus articulos/ \
  --lang es \
  --top-k 100 \
  --output terminos_academicos.csv

# Ve los 20 primeros
head -20 terminos_academicos.csv
```

Ejemplo 2: Glosario Bilingüe

Extrae y compara términos en inglés/español:

```python
from tecla import HybridTermExtractor

# Inglés
docs_en = [{"text": "corpus linguistics...", "doc_id": "doc1", "language": "en"}]
docs_es = [{"text": "lingüística de corpus...", "doc_id": "doc1", "language": "es"}]

extractor_en = HybridTermExtractor(language="en")
extractor_es = HybridTermExtractor(language="es")

terminos_en = extractor_en.extract(docs_en, top_k=20)
terminos_es = extractor_es.extract(docs_es, top_k=20)

# Crea glosario bilingüe
glosario = []
for termino_en, termino_es in zip(terminos_en, terminos_es):
    glosario.append({
        "english": termino_en['text'],
        "spanish": termino_es['text']
    })

# Exporta
import json
with open('glosario_bilingue.json', 'w', encoding='utf-8') as f:
    json.dump(glosario, f, ensure_ascii=False, indent=2)
```

Ejemplo 3: Evaluación de Calidad del Corpus

Evalúa el corpus antes de la extracción:

```bash
# Obtén estadísticas
python -m tecla stats --corpus corpus/ --lang es

# Un buen corpus tiene:
# - TTR > 0.3 (vocabulario rico)
```

```
# - Heaps   entre 0.3-0.7 (crecimiento equilibrado)
# - Mínimo 10.000 tokens
```

Solución de Problemas

Problema: "spaCy model not found"

Solución:

```
python -m spacy download es_core_news_md
python -m spacy download en_core_web_md
```

Problema: "Module 'tecla' not found"

Solución:

```
# Instala TECLA primero
pip install -e /ruta/a/tecla

# O añade a PYTHONPATH
export PYTHONPATH=/ruta/a/tecla:$PYTHONPATH
```

Problema: Salida CSV vacía

Posibles causas: - La carpeta del corpus está vacía (verifica permisos) - La configuración de idioma no coincide con el idioma del corpus - El corpus es demasiado pequeño (<1.000 tokens)

Solución:

```
# Prueba con texto de muestra
echo "Este es un corpus de prueba para extracción de terminología." > prueba.txt
python -m tecla extract --corpus ./ --lang es --top-k 5
```

Problema: Extracción lenta

Consejos de optimización: - Reduce el valor de `--top-k` - Usa un corpus más pequeño para pruebas - Cierra otras aplicaciones - Asegúrate de que el modelo de spaCy está en caché

Configuración Avanzada

Pesos de Puntuación Personalizados

Ajusta el balance entre TF-IDF y C-value:

```
extractor = HybridTermExtractor(
    language="es",
    config={
        "tfidf_weight": 0.7,      # Aumenta peso de TF-IDF
        "c_value_weight": 0.3,    # Disminuye peso de C-value
        "min_frequency": 3,       # Mínimo de ocurrencias
```

```
        "min_length": 2,          # Mínimo de tokens por término
        "max_length": 4,          # Máximo de tokens por término
    }
)
```

Filtrado de Términos

Filtra resultados por criterios:

```
# Solo términos de alta calidad
filtrados = [t for t in terminos if t['score'] > 0.7]

# Solo términos multipalabra
multipalabra = [t for t in terminos if ' ' in t['text']]

# Alta frecuencia de documentos
comunes = [t for t in terminos if t['doc_frequency'] >= 3]
```

Citación

Si utilizas TECLA en investigación, por favor cita:

```
@phdthesis{moyano2026,
  title={Extracción Automática de Terminología mediante Métodos Híbridos Lingüístico-Estadísti
  author={Moyano, Isabel},
  school={Universidad de Cádiz},
  year={2026}
}
```

Soporte

Para problemas, preguntas o solicitudes de características:

- **Email**: isabel.moyano@gm.uca.es
- **Repositorio**: GitHub (enlace en README)
- **Documentación**: Ver `/tecla/README.md`

Referencia Rápida

Comandos CLI

```
# Extraer términos
python -m tecla extract --corpus CORPUS --lang es --top-k 50

# Obtener estadísticas
python -m tecla stats --corpus CORPUS --lang es
```

```
# Evaluar resultados
python -m tecla evaluate --predicted TERMINOS.csv --gold-standard REF.txt

# Lanzar GUI
python gui/tecla_gui.py

# Obtener ayuda
python -m tecla extract --help
```

API Python

```
from tecla import HybridTermExtractor, corpus_statistics

# Extraer
extractor = HybridTermExtractor(language="es")
terminos = extractor.extract(documentos, top_k=50)

# Estadísticas
estadisticas = corpus_statistics("corpus/", language="es")

# Resultados
for termino in terminos[:5]:
    print(f"{termino['text']}: {termino['score']:.3f}")
```

TECLA v2.0.0 | © 2026 | Licencia MIT