

TECLA: guía de uso

Versión 2.0.0

Índice

1. Qué es TECLA **2**

2. Instalación **2**
2.1. Requisitos . . . 2
2.2. Pasos . . . 2
2.3. Abrir la interfaz gráfica . . . 2
2.4. Probar TECLA sin instalar nada . . . 2

3. Preparar la carpeta de trabajo **3**

4. La interfaz gráfica, paso a paso **3**
4.1. Antes de ejecutar . . . 4
4.2. Paso 1: Corpus . . . 4
4.3. Paso 2: Extracción . . . 5
4.4. Paso 3: Evaluación . . . 6
4.5. Paso 4: Revisión . . . 7

5. Opciones avanzadas **8**

6. Qué archivos genera **8**

7. Línea de comandos **9**
7.1. Extraer . . . 9
7.2. Estadísticas del corpus . . . 9
7.3. Evaluar una extracción . . . 9

8. Uso desde Python **10**

9. Problemas frecuentes **11**

10. Licencia y contacto **11**

1. Qué es TECLA

TECLA es una herramienta de código abierto para trabajar con la terminología de un dominio a partir de sus textos. Reúne en un mismo entorno las fases del trabajo terminográfico basado en corpus:

1. **preparar el corpus**: convertir los documentos a texto, limpiarlos y analizarlos lingüísticamente;
2. **extraer los candidatos a término**, combinando patrones gramaticales y medidas estadísticas;
3. **comprobar si el corpus es suficiente** para representar la terminología del dominio;
4. **revisar** los candidatos y **exportar** el inventario.

Puede usarse de tres maneras: con una interfaz gráfica de escritorio, que no exige programar; desde la línea de comandos; y desde un programa en Python. Las tres se apoyan en los mismos módulos y, con los mismos parámetros, producen los mismos resultados.

TECLA se ejecuta en el propio ordenador: los documentos no se envían a ningún servidor. Trabaja con textos en **español** y en **inglés**.

- Página de presentación: https://isabel-mm.github.io/TECLA/
- Código fuente: https://github.com/isabel-mm/TECLA

2. Instalación

2.1. Requisitos

- Python 3.9 o superior.
- Git, para descargar el código.
- Unos 2 GB de espacio libre, sobre todo para los modelos lingüísticos.

2.2. Pasos

En una terminal (en Windows, el Símbolo del sistema o PowerShell):

```
git clone https://github.com/isabel-mm/TECLA.git
cd TECLA
pip install -e .
```

A continuación se descargan los modelos lingüísticos de spaCy, uno por lengua:

```
python -m spacy download es_core_news_md
python -m spacy download en_core_web_lg
```

Basta con instalar el de la lengua con la que se vaya a trabajar. Si un modelo no está instalado, TECLA intenta descargarlo la primera vez que lo necesita.

2.3. Abrir la interfaz gráfica

```
python gui/tecla_gui.py
```

2.4. Probar TECLA sin instalar nada

El repositorio incluye un cuaderno de demostración para Google Colab, que ejecuta la extracción y la evaluación sobre unos pocos textos desde el navegador:

https://colab.research.google.com/github/isabel-mm/TECLA/blob/main/TECLA_colab_demo.ipynb

Incluye unos textos sintéticos de prueba. Es una muestra, no la forma de trabajo: los textos que se cargan en el cuaderno se copian a una sesión de Google, por lo que no deben usarse documentos confidenciales ni sujetos a derechos de autor.

3. Preparar la carpeta de trabajo

TECLA trabaja sobre una **carpeta de trabajo** que contiene una subcarpeta llamada `corpus` con los documentos, en PDF o en texto plano (TXT):

```
mi_proyecto/                <- carpeta de trabajo
└── corpus/
    ├── 2019_Autor_Titulo.pdf
    ├── 2021_Autor_Titulo.pdf
    └── ...
```

Dos recomendaciones:

- **Una sola lengua por corpus.** La gramática de patrones y el modelo lingüístico se eligen para todo el corpus.
- **Nombres de archivo informativos.** Si el nombre sigue un esquema del tipo `año_autor_título`, TECLA deduce de él el autor, el año y el título de cada documento, que después pueden corregirse a mano.

Todo lo que TECLA genera se guarda dentro de la carpeta de trabajo (véase la sección «Qué archivos genera»); los documentos originales no se modifican.

4. La interfaz gráfica, paso a paso

La ventana tiene dos zonas. A la izquierda, el **panel de configuración**: carpeta de trabajo, lengua, tipo de candidatos, perfil de puntuación, opciones avanzadas y el botón *Ejecutar*. A la derecha, las **cuatro pantallas** del flujo, a las que se accede por los pasos numerados de la parte superior: *Corpus*, *Extracción*, *Evaluación* y *Revisión*. El paso en curso aparece resaltado y los completados quedan marcados.

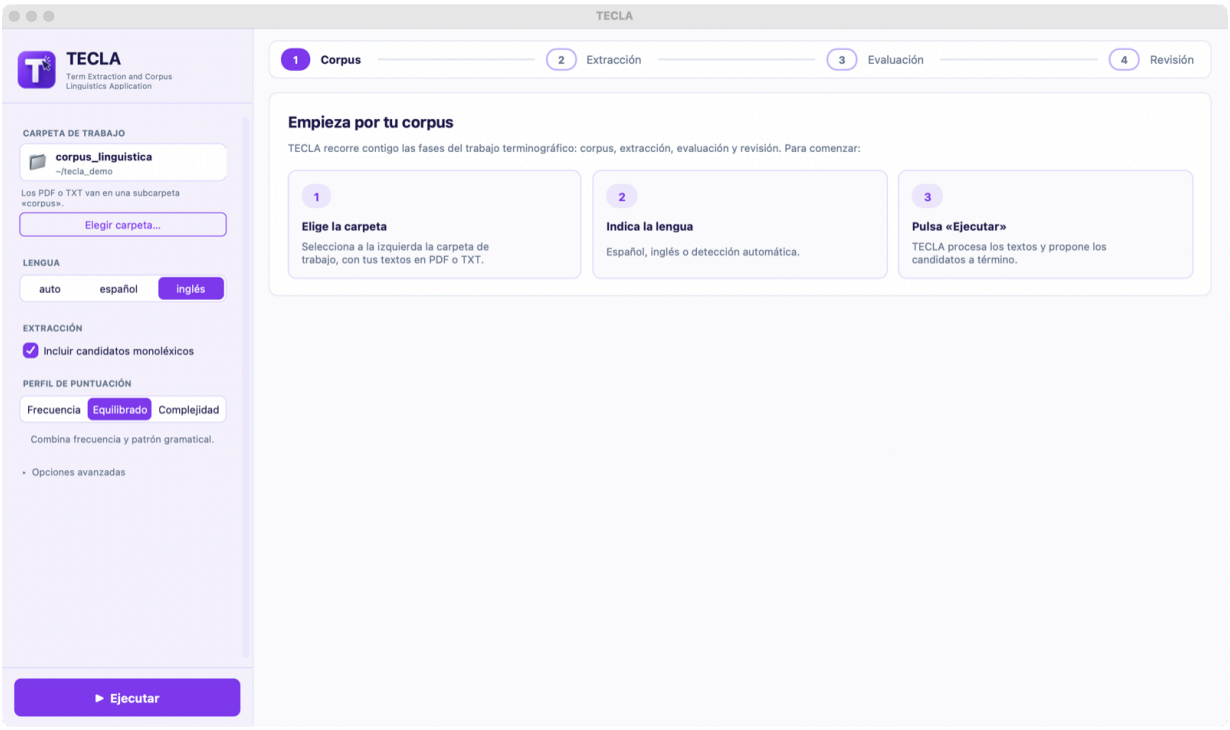


Figura 1: Pantalla inicial.

4.1. Antes de ejecutar

1. **Carpeta de trabajo.** Se pulsa *Elegir carpeta…* y se selecciona la carpeta de trabajo (la que contiene la subcarpeta `corpus`).
2. **Lengua.** *Español*, *inglés* o *auto*, que la detecta a partir de los textos.
3. **Candidatos monoléxicos.** Por defecto solo se extraen candidatos de dos o más palabras. Si se marca *Incluir candidatos monoléxicos*, se extraen también los de una palabra.
4. **Perfil de puntuación.** Decide cuánto pesa cada medida en el índice de terminologicidad:
   - *Frecuencia* (0,6 para el *TF-IDF* y 0,4 para el *NC-value*): favorece los candidatos muy presentes en el corpus.
   - *Equilibrado* (0,5 y 0,5): es el valor por defecto.
   - *Complejidad* (0,2 y 0,8): favorece los candidatos de varias palabras bien delimitados por su contexto.
5. Se pulsa **Ejecutar**. El registro del proceso muestra cada etapa. El análisis lingüístico es la más lenta: un corpus de un millón y medio de palabras tarda unos dos minutos en un ordenador portátil.

4.2. Paso 1: Corpus

Muestra las cifras del corpus (documentos, *tokens*, oraciones, tipos y relación entre tipos y *tokens*) y una tabla con los datos de cada documento:

Columna	Qué indica
Tokens	Número de palabras y signos del documento
Oraciones	Número de oraciones
Tipos	Número de lemas distintos
TTR	Tipos entre *tokens*

Columna	Qué indica
Hápax	Proporción de tipos que aparecen una sola vez en el documento
Dens. léx.	Proporción de palabras de contenido entre las palabras
Long. or.	*Tokens* por oración, de media

Al seleccionar un documento, el panel inferior permite completar o corregir sus **metadatos** (autor, año, tema, fuente y notas). El botón *Exportar CSV* guarda la tabla completa.

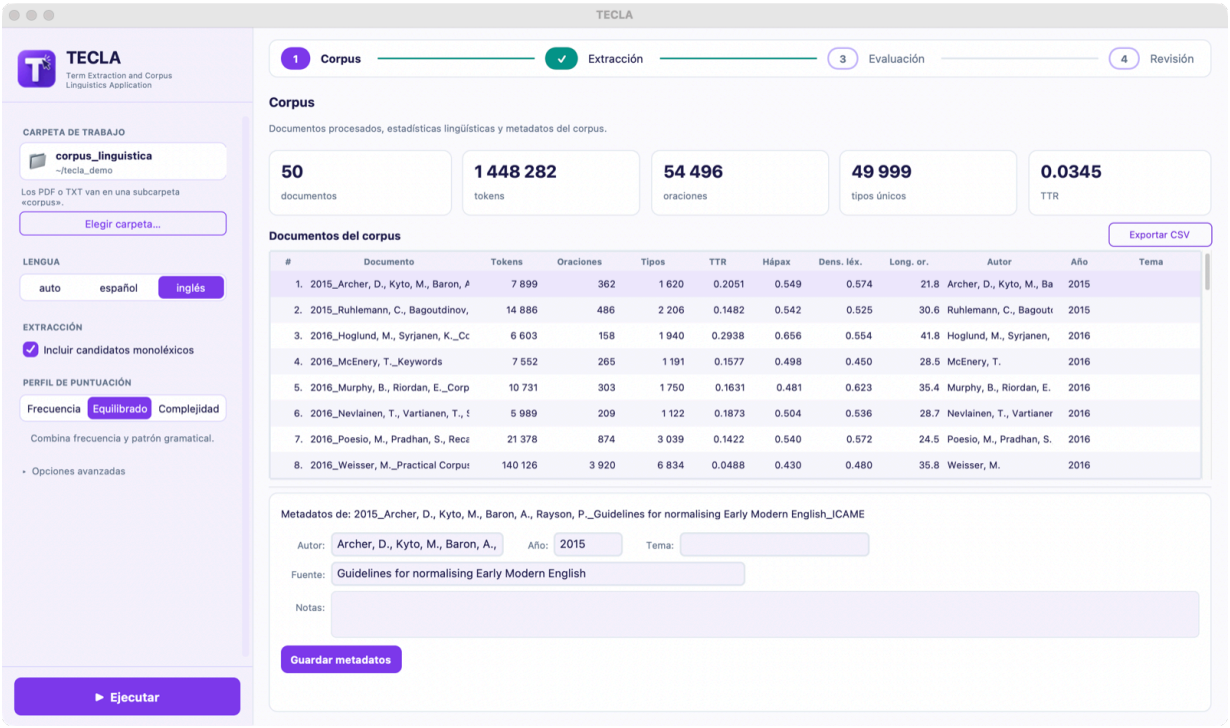


Figura 2: Pantalla Corpus.

4.3. Paso 2: Extracción

La extracción tiene dos etapas. La primera es **lingüística**: se buscan en el texto las secuencias que siguen los patrones gramaticales habituales de los términos de cada lengua (por ejemplo, un nombre seguido de un adjetivo en español, o una serie de nombres en inglés). La segunda es **estadística**: para cada candidato se calculan varias medidas, que se combinan en un **índice de terminologicidad** entre 0 y 1.

Columna	Qué indica
Candidato	Forma lematizada del candidato
Variantes	Otras formas con que aparece en los textos (plural, mayúsculas, guiones) y, en su caso, la sigla o la forma desarrollada
Score	Índice de terminologicidad, con una barra que lo representa
TF-IDF	Frecuencia ponderada por el número de documentos en que aparece

Columna	Qué indica
C-val	*C-value*: penaliza a los candidatos que aparecen sobre todo dentro de otros más largos
NC-val	*NC-value*: amplía el *C-value* con la información de las palabras que rodean al candidato
Frec	Frecuencia absoluta
Frec/mil	Frecuencia por mil *tokens*
Docs	Número de documentos en que aparece

La tabla puede **ordenarse** por cualquiera de las medidas, y las columnas pueden mostrarse u ocultarse con las casillas de la fila *Columnas*. Los botones *CSV* y *TBX* exportan los candidatos seleccionados o, si no hay ninguno seleccionado, todos los que se muestran.

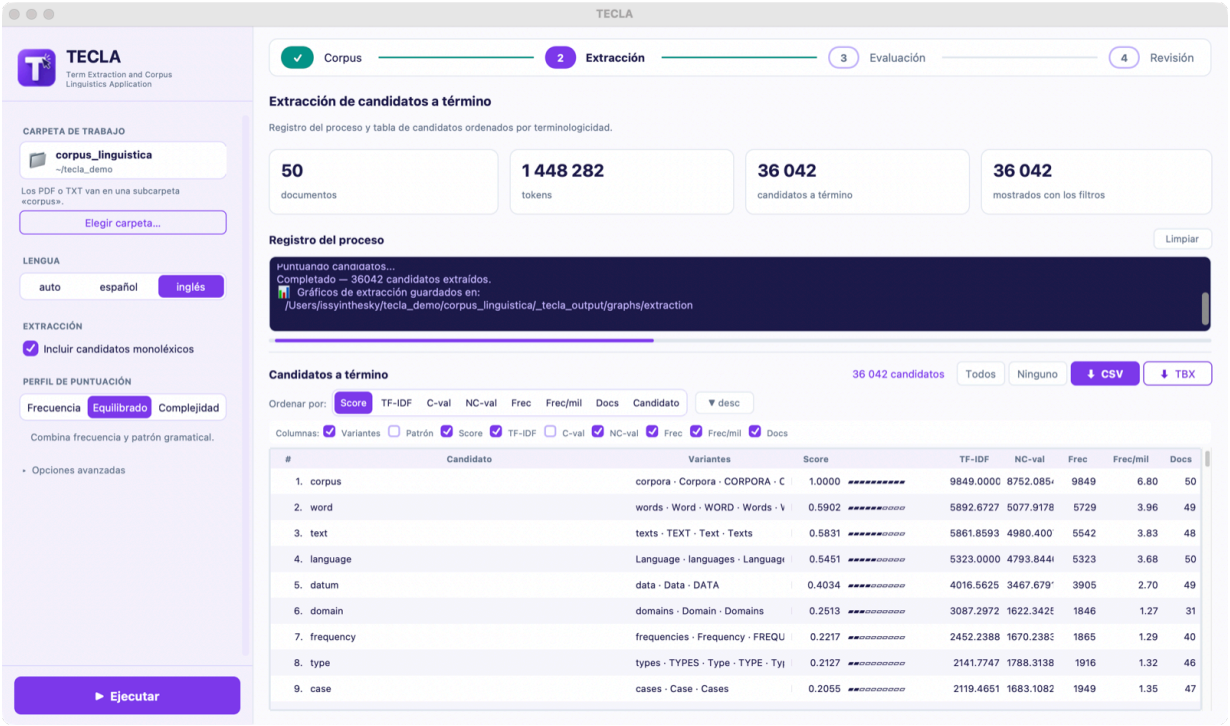


Figura 3: Pantalla Extracción.

4.4. Paso 3: Evaluación

Responde a una pregunta que conviene hacerse antes de dar por bueno un inventario: ¿recoge este corpus la terminología del dominio de forma suficiente? Se pulsa *Calcular representatividad* y TECLA muestra:

- El **Índice de Representatividad Terminológica (IRT)**, de 0 a 100, con una etiqueta (de «escasamente representativo» a «muy representativo») y un texto que separa lo que juega a favor y en contra. Promedia cuatro componentes:
  - *saturación*: si el vocabulario deja de crecer al añadir textos (ley de Heaps);
  - *hápax*: qué proporción de los lemas aparece una sola vez;
  - *dispersión*: si los candidatos principales se reparten por los documentos (medida DP);

    - *estabilidad*: si el núcleo del inventario se mantiene al cambiar los documentos (re-muestreo).
- La **dispersión de cada candidato** (DP). Un valor próximo a 0 indica que el candidato se reparte por todos los documentos; uno próximo a 1, que se concentra en uno o en unos pocos, de modo que puede ser un uso propio de un autor.
- Los **gráficos**: crecimiento del vocabulario, dispersión y distribución de frecuencias.

El IRT es una orientación rápida. Sus umbrales son convenciones de la herramienta, no valores validados empíricamente: conviene leerlo junto con sus componentes y no como un veredicto.

Dos análisis opcionales necesitan un fichero aportado por el usuario:

- **Cobertura frente a una lista de referencia.** Con *Cargar lista…* se carga un CSV con una columna llamada `term` (un glosario, por ejemplo), y TECLA indica qué parte de esa lista aparece entre los candidatos.
- ***Keyness* frente a un corpus de referencia.** Con *Cargar referencia…* se carga un CSV con una columna de lemas y otra de frecuencias, y TECLA calcula qué candidatos son característicos del corpus analizado frente a ese corpus de referencia.

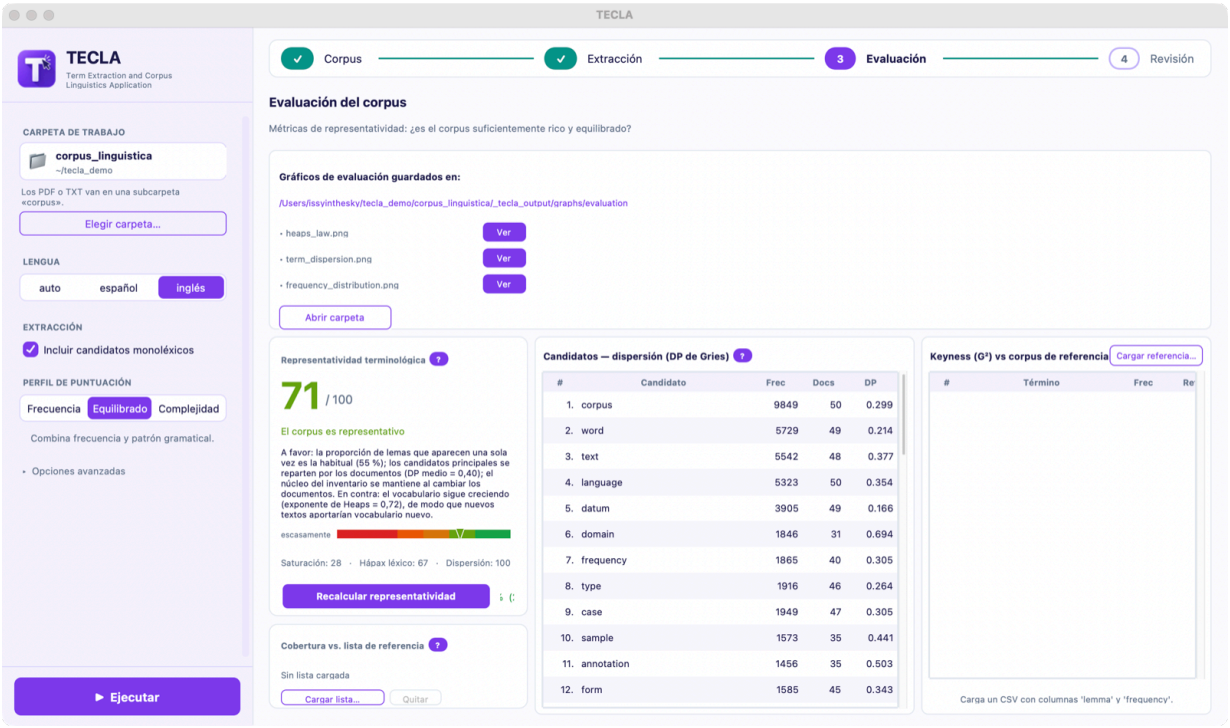


Figura 4: Pantalla Evaluación.

4.5. Paso 4: Revisión

Ningún sistema automático sustituye el juicio del especialista. En esta pantalla cada candidato se marca como *aprobado*, *rechazado* o *pendiente*, y se le pueden añadir notas. La lista de la izquierda puede filtrarse por estado, y el panel de la derecha muestra todas las cifras del candidato seleccionado.

La revisión se guarda automáticamente en la carpeta de trabajo, de modo que puede retomarse donde se dejó. Cuando el corpus produce muchos candidatos, la lista muestra los 300 primeros; el filtro por estado permite llegar al resto.

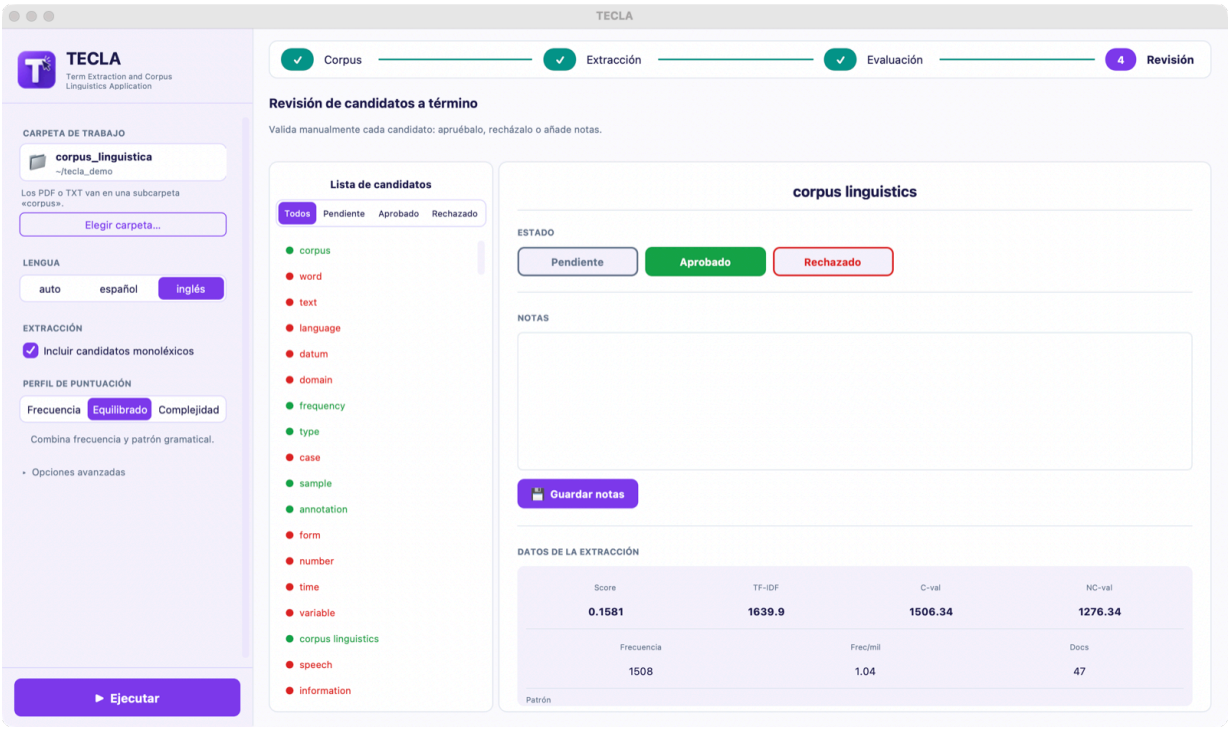


Figura 5: Pantalla Revisión.

5. Opciones avanzadas

Se despliegan en el panel de la izquierda, bajo *Opciones avanzadas*:

- **Stoplist adicional.** Palabras, separadas por comas, que no deben formar parte de ningún candidato. También puede cargarse desde un fichero de texto, con una palabra por línea.
- **Gramática POS personalizada.** Por defecto se usa la gramática de patrones incluida, que cubre el español y el inglés. Puede sustituirse por un fichero `.yaml` propio, por ejemplo para adaptarla a un dominio.
- **Longitud máxima de los candidatos**, en *tokens* (por defecto, 5).
- **Filtros** sobre la lista ya extraída: frecuencia mínima, exclusión de los hápax, percentil mínimo y valor mínimo del índice. No repiten la extracción: solo cambian lo que se muestra y lo que se exporta.

6. Qué archivos genera

Todo queda dentro de la carpeta de trabajo:

Archivo o carpeta	Contenido
`corpus/_tecla_txt/raw/`	Los documentos convertidos a texto, sin limpiar
`corpus/_tecla_txt/clean/`	Los textos limpios, que son los que se analizan
`corpus/metadata.csv`	Autor, año y título deducidos del nombre de cada archivo
`_tecla_metadata.json`	Los metadatos corregidos a mano

Archivo o carpeta	Contenido
`_tecla_revision.json`	El estado y las notas de cada candidato revisado
`_tecla_output/graphs/extraction/`	Gráficos de la extracción (PNG)
`_tecla_output/graphs/evaluation/`	Gráficos de la evaluación (PNG)
`_tecla_output/tecla_debug.txt`	Registro de tiempos de cada etapa, útil si un proceso va lento

El inventario se exporta, además, en dos formatos, donde el usuario indique:

- **CSV**: una fila por candidato, con todas sus cifras.
- **TBX-Basic** (ISO 30042): el estándar de intercambio terminológico, con las variantes de cada candidato.

7. Línea de comandos

Para automatizar tareas o procesar varios corpus seguidos, TECLA ofrece la orden `tecla` con tres operaciones.

7.1. Extraer

```
tecla extract --corpus mi_proyecto/corpus --lang es \
      --structure --remove-bibliography \
      --output candidatos.csv --tbx candidatos.tbx
```

Opción	Qué hace
`--corpus`	Carpeta con los documentos (obligatoria)
`--lang`	Lengua: `es` o `en` (obligatoria)
`--output`	Ruta del CSV de salida
`--tbx`	Ruta del TBX de salida
`--multiword`	Solo candidatos de dos o más palabras
`--top-k`	Número máximo de candidatos
`--percentile`	Conserva solo el percentil superior de la lista
`--structure`	Limpia el ruido estructural (números de página, líneas sueltas)
`--remove-bibliography`	Elimina el bloque de referencias
`--lemmatize`	Lematiza durante la limpieza
`--tfidf-weight`	Peso del *TF-IDF* en el índice (por defecto, 0,5); el del *NC-value* es el resto

7.2. Estadísticas del corpus

```
tecla stats --corpus mi_proyecto/corpus/_tecla_txt/clean --lang es --output corpus.csv
```

Calcula, para cada texto, los *tokens*, los tipos, la relación entre ambos, la proporción de hápax, la densidad léxica, el número de oraciones y su longitud media.

7.3. Evaluar una extracción

```
tecla evaluate --extracted candidatos.csv --gold glosario.csv --mode lemma --verbose
```

Compara una extracción con una lista de referencia y calcula la precisión, la cobertura y el F1. Las columnas que se comparan se llaman `term` por defecto y pueden cambiarse con `--extracted-col` y `--gold-col`. El modo `exact` compara las formas tal cual; el modo `lemma`, sus lemas.

8. Uso desde Python

El flujo completo puede lanzarse con una sola función:

```python
from pathlib import Path
from pipeline.pipeline import run_tecla_pipeline

candidatos = run_tecla_pipeline(
    corpus_path=Path("mi_proyecto/corpus"),
    language="es",                      # "es", "en" o None para detectarla
    cleaning_options={
        "structure": True,
        "remove_bibliography_flag": True,
        "remove_captions_flag": True,
        "remove_section_headers_flag": True,
    },
    extraction_options={
        "multiword_only": False,        # incluir candidatos monoléxicos
        "max_term_length": 5,
        "weights": {"tfidf": 0.5, "ncvalue": 0.5},
    },
)

candidatos.sort(key=lambda c: -c["terminologicity"])
for c in candidatos[:10]:
    print(c["lemma"], round(c["terminologicity"], 3), c["frequency"])
```

Cada candidato es un diccionario con estos campos:

Campo	Contenido
`lemma`	Forma lematizada
`term`	Forma más frecuente en los textos
`variants`	Otras formas
`patterns`	Patrones gramaticales con que se ha reconocido
`terminologicity`	Índice de terminologicidad (0 a 1)
`tf_idf`, `c_value`, `nc_value`	Las tres medidas
`frequency`, `freq_rel`, `doc_frequency`	Frecuencia absoluta, por mil *tokens* y número de documentos

Las operaciones de limpieza pueden activarse una a una mediante `cleaning_options`. Además de las cuatro del ejemplo, están disponibles `rejoin_hyphens_flag`, `remove_keyword_lines_flag`, `remove_urls_flag`, `remove_publication_metadata_flag`, `remove_inline_citations_flag`, `remove_journal_metadata_flag`, `remove_statistical_lines_flag`, `remove_stopwords_flag`, `lemmatize_flag` y `extra_stoplist`.

9. Problemas frecuentes

«No se encontró la carpeta ‘corpus’». La carpeta elegida debe ser la carpeta de trabajo, es decir, la que *contiene* la subcarpeta `corpus`, y no la subcarpeta misma.

No se extrae ningún candidato, o muy pocos. Lo más habitual es que la lengua seleccionada no sea la de los textos, o que el modelo lingüístico de esa lengua no esté instalado. Conviene comprobar la lengua y volver a ejecutar la orden `python -m spacy download` correspondiente.

Aparecen palabras generales entre los primeros candidatos. Es esperable: palabras como *texto* o *lengua* son muy frecuentes en cualquier corpus. Pueden añadirse a la *stoplist adicional*, o rechazarse en la pantalla de revisión.

Los PDF dan un texto con errores. La conversión depende de cómo se generó el PDF. Los PDF escaneados, que son imágenes, no contienen texto y deben pasarse antes por un programa de reconocimiento de caracteres (OCR). El resultado de la conversión puede comprobarse en `corpus/_tecla_txt/clean/`.

El proceso tarda mucho. El análisis lingüístico es proporcional al tamaño del corpus. El fichero `_tecla_output/tecla_debug.txt` indica cuánto tarda cada etapa.

Las cifras de la evaluación parecen poco fiables. Con corpus muy pequeños lo son: los cuatro componentes del índice necesitan un número razonable de documentos y de palabras para estabilizarse.

10. Licencia y contacto

TECLA se distribuye con licencia MIT. El código, las pruebas automáticas y la documentación están en https://github.com/isabel-mm/TECLA, donde también pueden comunicarse errores o sugerencias mediante la sección *Issues*.

El nombre es un acrónimo de *Term Extraction and Corpus Linguistics Application*.